



國立中山大學金融創新產業碩士專班

碩士論文

Department of Finance

National Sun Yat-sen University

Master Thesis

運用基本面、技術面及籌碼面

建構台股深度學習交易策略

Using Fundamental, Technical and Chip Factors to Construct  
Taiwan Stock Deep Learning Trading Strategies

研 究 生：陳子軒

Tzu-Hsuan Chen

指導教授：王昭文 博士

Dr. Chou-Wen Wang

中華民國 107 年 6 月

June 2018

# 論文審定書

## 國立中山大學研究生學位論文審定書

本校金融創新產業碩士專班

研究生陳子軒（學號：M054810001）所提論文

運用基本面、技術面及籌碼面建構台股深度學習交易策略  
Using Fundamental, Technical and Chip Factors to Construct Taiwan Stock Deep  
Learning Trading Strategies

於中華民國 107 年 6 月 25 日經本委員會審查並舉行口試，符合碩士學位論文標準。

學位考試委員簽章：

召集人 黃振聰

委員 王昭文

委員 黃泓智

委員 吳錦文

委員

委員

指導教授(王昭文)

(簽名)

## 致 謝

再過幾個月就要先告別學生的身分了，首先感謝爸媽的栽培，除了讓我衣食無缺，也在背後支持我追尋自己的夢想。碩士班兩年，最感謝兩個人，一位是我的指導老師，王昭文教授，帶我進入量化投資的領域，也讓我找到未來的方向；而另一位是蘇彥庭學長，這兩年給了我們許多幫助，不僅教我們寫程式，也給我們許多論文、職涯上的建議。此外，也要感謝中山大學和玉山銀行，給我一個很好的機會，能夠同時學到學術知識與實務經驗，最後，感謝思羽及同學們，讓我在這兩年留下許多美好的回憶。

展望未來，結束學生的身分不代表求學生涯已結束，希望自己能保持一顆求知若渴的心，一點一滴累積競爭力；也希望自己勇於面對一切困難，能在逆境中力爭上游；最後，將自己所得到的，帶給家人、學校以及整個社會。



## 摘 要

股票分析方法可分為三大面向：基本、技術以及籌碼分析。市場上三大分析方法皆有其支持者，基本面支持者相信股價終將回歸合理價值；技術面支持者認為股價走勢能即時反應當前股票狀況，並相信歷史會不斷重演；籌碼面支持者認為對市場有影響力的交易人才是影響股價走勢的主因。本研究認為結合三大面向分析方法應能達到相輔相成的效果，透過三大分析確認買進訊號，不僅有助於提升策略績效，亦能強化投資人對於策略的信心。

此交易策略使用深度學習模型，以財報資訊做為訓練資料，於每季進行基本面選股，挑出預期下一季表現強勢的股票，以此為股票池，當技術與籌碼分析發出買進賣出訊號時，才執行買進賣出，技術面的訊號設計由經典的均線指標所構成，而籌碼面的訊號則由投信買賣超經過處理後設計而成，因本研究認為投信相較於外資、自營商的操作動機最為單純。實證結果顯示，深度學習結合基本面之模型經過 47 期的滾動樣本測試，強弱勢依分數高低各選出 500 檔股票，每季的強弱勢平均報酬差距有 3.67%，隨著分數越高減去越低的組合，50 檔每季的強弱勢平均報酬差距能夠達到 6.93%，顯示此模型能夠有效且穩定分辨強弱勢股票；技術與籌碼擇時策略的部分，在技術面條件不變下，不論是平均單筆交易或是模擬基金的績效，投信買賣指標之績效皆優於外資及自營商的買賣指標；最後結合兩策略，約十年的回測期間下，年化報酬可達 26.86%，夏普值 1.13，皆優於結合前策略的績效，實屬表現良好之交易策略，此結果驗證了本研究欲傳達之理念：

1. 三大分析皆有其價值，適當結合能達相輔相成的效果，亦能強化投資人執行策略之信心

2. 深度學習對於現今而言雖屬黑盒子，但其確實能有效運用於交易策略上

在穩健性測試的部分，透過多輪的訓練，此策略之深度學習選股模型的績效表現並無太大的落差；而投信買賣指標的參數敏感度測試結果顯示，除了過高和過低的參數外，其餘參數和績效具有正向關係，顯示此擇時進出策略具備相當程度之穩定性，整體而言，本策略之參考價值獲得進一步的提升。

關鍵字：深度學習、基本面、技術面、籌碼面

## Abstract

In Taiwan stock market, there are three major ways to analyze the stocks. The first is fundamental factors analysis, evaluating the value of a company by analyzing financial statements, the company's pros and cons, industrial situation, and so on. The second is technical factors analysis, forecasting the stock price through patterns of the stock price or the candlestick, technical indicators calculated by price and volume, such as moving average(MA), relative strength index(RSI), and others. The last is "chip" factors analysis, predicting future performance of the stock price by tracking institutional investors' behavior, like foreign investors, dealers, and investment trusts. The purpose of this study is to prove that combination of three major stock analyses could make trading strategies more profitable. In addition, this study also employs the deep learning technology to construct better trading strategies.

This study constructs a composite trading strategy of Taiwan equity market which could be divided into two phases. The first phase is using the deep learning model trained by 129 indicators from financial statements to select strong stocks in next season, which form a stock pool. The second phrase is to buy and sell stocks from the stock pool according to signals consisting of technical indicators and a chip indicators. The results of this study reveal that the composite strategy has an annual return up to 26.86%, a max drawdown equal to 33.13%, and a Sharpe ratio equal to 1.13. All of them are better than the respective performances of the deep learning models and the timing strategies. There are two conclusions of this study:

1. Moderately integrating three major stock analyses could improve a trading strategy performance and enhance investors' confidence.
2. A well-defined deep learning is useful to construct trading strategies in practice.

Key words: deep learning, fundamental factors, technical factors, chip factors

# 目 錄

論文審定書 .....	i
致 謝 .....	ii
摘 要 .....	iii
Abstract .....	iv
目 錄 .....	v
圖 次 .....	vi
表 次 .....	vii
第一章 緒論 .....	1
第一節 研究背景動機 .....	1
第二節 研究目的 .....	3
第三節 研究架構與流程 .....	4
第二章 文獻探討 .....	5
第一節 三大分析 .....	5
第二節 深度學習 .....	11
第三章 研究方法 .....	14
第一節 實驗架構 .....	14
第二節 資料蒐集與建立 .....	16
第三節 量化策略建構 .....	18
第四節 績效評估指標 .....	33
第四章 實證結果 .....	36
第一節 策略績效 .....	36
第二節 穩健性測試 .....	48
第五章 結論與建議 .....	56
第一節 結論 .....	56
第二節 後續建議 .....	57
參考文獻 .....	59
第一節 中文文獻 .....	59
第二節 英文文獻 .....	61
附錄 .....	63

## 圖 次

圖 3-1 實驗架構圖 .....	15
圖 3-2 單一神經元結構示意圖 .....	23
圖 3-3 單層類神經網絡示意圖 .....	25
圖 3-4 滾動樣本回測示意圖 .....	29
圖 4-1 強弱勢各期報酬差距 .....	36
圖 4-2 強弱勢整體平均差距 .....	37
圖 4-3 各組合基金累積報酬走勢圖 .....	39
圖 4-4 技術結合籌碼策略基金累積報酬走勢 .....	43
圖 4-5 三大分析策略基金累積報酬走勢圖 .....	47
圖 4-6 模型平均表現 .....	49
圖 4-7 各資金規模在流動性限制下之策略基金累積報酬走勢 .....	52
圖 4-8 各參數下策略平均報酬 .....	54
圖 4-9 各參數之策略基金累積報酬走勢 .....	55

## 表 次

表 3-1 三大分析所需資料 .....	17
表 3-2 財務結構指標 .....	19
表 3-3 損益指標 .....	21
表 3-4 其他財務指標 .....	22
表 3-5 深度學習模型設定 .....	28
表 3-6 財報最後公布日 .....	29
表 3-7 進出場訊號條件彙整 .....	33
表 4-1 各組合強弱勢報酬 T 檢定結果.....	37
表 4-2 各組合基金績效 .....	38
表 4-3 技術結合籌碼策略平均績效 .....	40
表 4-4 技術結合籌碼策略報酬 T 檢定結果.....	41
表 4-5 技術結合籌碼策略基金績效 .....	42
表 4-6 三大分析策略平均績效 .....	45
表 4-7 三大分析策略報酬 T 檢定結果.....	46
表 4-8 三大分析策略基金績效 .....	46
表 4-9 各資金在流動性限制下基金績效 .....	51
表 5-1 各策略績效統整 .....	56



# 第一章 緒論

## 第一節 研究背景動機

股票分析方法可分為三大面向：基本、技術以及籌碼分析。基本分析利用公司的財務報表，搭配產業前景、產品優劣等資訊，對公司的價值進行評估，買進遭到低估的股票，持有至股價回升至合理價格或是高估時予以賣出。技術分析使用歷史股價、成交量及其衍生指標對未來的股價漲跌做出判斷，例如：K線分析利用每日的開、高、低、收價格形成K棒，判斷當前股價強弱，廣為人知的移動平均線將過去一段期間的股價計算平均值，用於觀察股價趨勢，並透過長短期均線關係判斷未來股價走勢，除此之外，尚有許多技術指標(KD、MACD、RSI...)、股價走勢型態、波浪理論皆屬於技術分析的範疇。籌碼分析則是針對特定交易人的買賣、持股進行分析，判斷未來股價強弱，例如：三大法人(外資、投信、自營商)的買賣超、融資融券的升減及餘額、券商分點的買賣狀況、董監事及大股東持股的變動...等等。市場上三大分析方法皆有其支持者，基本面支持者相信股價終將回歸合理價值；技術面支持者認為股價走勢能即時反應當前股票狀況，並相信歷史會不斷重演；籌碼面支持者認為對市場有影響力的交易人才是影響股價走勢的主因。本研究認為結合三大面向的分析方法或能達到相輔相成的效果，透過三大分析確認買進訊號，不僅有助於提升策略績效，亦能強化投資人對於策略的信心。

金融科技(Fintech)無疑是近年來最火熱的議題之一，科技進步為各方面帶來許多衝擊，例如：電子支付大幅地提升收付款效率及體驗；區塊鏈解決保險資訊不對稱的問題；機器人理財為財富管理帶來不一樣的投資模式，過去多以銀行自家觀點以及理財專員的規劃為顧客的配置資產，而現在能透過巨量資料快速取得、運算以及人工智慧進行全面、快速的量化配置。根據資誠聯合會計師事務發布的《資誠 2017 全球金融科技調查報告》，當中提到未來有三項重要

的科技將持續為金融業帶來深遠的影響，分別是：人工智慧、區塊鏈、機器流程自動化，台灣各家金融業者亦紛紛搶進這些新興科技以求脫穎而出。人工智慧的初步實踐來自於機器學習(Machine learning)，透過歷史樣本進行學習，進而建立具備預測能力的模型，如同人類一般，透過歷史經驗的學習便可進行判斷。深度學習為機器學習的一種，其特別之處在於整體架構的設計類似生物的神經網絡系統，擁有多層神經網絡，每層神經網絡都有數個神經元，每個神經元皆是一個非線性函數，透過樣本資料的訓練，調整神經元的權重參數，進而建立預測結果最準確的模型。

量化交易策略是透過自身交易、投資邏輯轉化而成的，而這些邏輯來自於過去的經驗，同理，深度學習或能協助我們完成這件工作，透過歷史資料的訓練，尋找規則，判斷出未來可能上漲的股票。因此本研究不僅著重於結合三大分析的量化交易策略，更結合目前的趨勢科技，將深度學習應用於交易與投資領域。

## 第二節 研究目的

本研究欲達成的目的如下：

- (一) 建構結合深度學習與三大分析的量化交易策略
- (二) 確認深度學習應用於量化交易策略的可行性
- (三) 驗證三大分析的結合有助於策略表現

除了上述三大議題外，本研究將實務上可能遇到的狀況納入考量，提高此策略應用於真實市場的可行性，例如：在策略中添加流動性的限制，因為市場上實際的成交量可能無法滿足策略的配置目標，過度龐大的買單亦可能造成買進成本偏離本研究所模擬的初始成本，降低此篇研究成果的參考價值；此外本研究亦加入資金胃納的測試，即是檢驗策略在不同的資金規模下，是否仍能維持績效水準，也能看出本策略最適資金配置水位。有了這些檢驗來強化本研究之結果，期許本研究不僅能供學術討論，此策略之可行性對於法人或個人投資者亦有參考價值，此為本研究希望帶來的貢獻。

### 第三節 研究架構與流程

本研究分成五個章節，依序為緒論、文獻探討、研究方法、實證結果以及結論與建議。主要章節內容敘述如下：

第一章 緒論，主要概述研究技術、籌碼、基本分析以及深度學習的背景動機及研究流程，大致說明本篇研究所要探討的之架構。

第二章 文獻探討，主要探討國內外相關文獻，從技術面、籌碼面以及基本面相關文獻中，尋找建構下一章研究方法的交易策略之想法，並簡要介紹與深度學習模型相關的研究，透過此部分進而優化本篇研究所建構的深度學習模型，使其有更好的表現。

第三章 研究方法，介紹研究資料及來源、整體的回測流程，並透過交易策略的架構，以及後續的績效評估方法，達到本篇研究所要探討的重點。

第四章 實證結果，檢視第三章交易策略之回測結果並加以分析，判斷策略優劣，逐步形成本研究之結論，接續進行穩健性測試，再次強化本篇研究結果，提升可信度、可能性。

第五章 結論及建議，根據實證結果檢視當初所設定的研究目標是否達成，並闡述本研究欲傳達之價值及貢獻，最後針對研究後續發展提供想法及建議

## 第二章 文獻探討

本章第一節探討基本面、技術面及籌碼面此三大分析之相關文獻，發掘建立策略的依據及想法，第二節為深度學習的相關文獻介紹。

### 第一節 三大分析

#### (一) 技術分析

技術分析的有效性來自於 Fama(1970)效率市場假說中的弱式市場不成立，即投資人可以利用過去的資訊(股價、成交量等等)獲得超額報酬，有許多研究已證實在特定市場下，技術分析具有獲利、預測力：

Hsu, Hsu and Kuan (2010)使用移動平均線指標以及濾嘴法則作為交易策略的進出場條件，共有 16,380 種組合，測試美國成長類股(S&P SmallCap 600, Russell2000, NASDAQ Composite)和其相關的 ETF、新興市場指數(MSCI 新興市場指數、MSCI 巴西指數、MSCI 馬來西亞指數、MSCI 墨西哥指數)，發現技術分析在新興市場更有預測力，但隨著近年市場效率性提升而逐漸減弱。

Szakmary, Shen and Sharma(2009)以 48 年，28 個商品期貨的月頻資料檢驗 MA 以及區間突破的順勢交易策略，其交易條件如下：

1. MA 策略：當短期移動平均線  $>$  長期移動平均線 $*(1+b\%)$ 進場做多，反之，當短期移動平均線  $<$  長期移動平均線 $*(1-b\%)$ 則做空
2. 區間突破策略：近一個月價格升破前  $x$  個月區間高點做多，近一個月價格跌破前  $x$  個月區間低點則做空

考量交易成本後，結果顯示大多數的參數組合皆能夠創造顯著的超額報酬，將策略應用到成交量相對高的市場，亦有不錯的績效。

Zhu, Atri and Yegen(2016)使用 1999 年至 2008 年，於上海及深圳交易所掛牌的所有股票，測試 10 種 K 線型態，分別是多/空頭吞沒型態、多/空頭孕育型態、多/空頭反沖型態、多/空頭孕育十字型態、多/空頭貫穿型態。結果顯示，空頭孕育、孕育十字形態在上漲趨勢中能準確捕捉到轉折點，而多頭貫穿、吞沒、孕育型態對震盪下跌趨勢的轉折具有良好的預測能力。在股票類型方面，多頭型態對於流動性較高的股票有較穩健的表現，而空頭型態則對規模小且流動性較低的股票有較佳的預測能力。

Chen, Bao and Zhou(2016)使用中國股市 2007 年至 2015 年間的日頻資料，回測 4 組常見的多空型態，每一組皆由兩天的 K 線組成，該研究給予這些型態明確的量化定義，並且使用 Step-SPA 降低數據窺探(Data snooping)的偏誤，結果顯示，多/空頭孕育(harami)型態、飛鴿歸巢(homing pigeon)型態，在中型股或大型股皆有良好的預測能力，然而最常被分析師提及的吞沒型態，只對於短期(兩天)股價具備顯著的預測力。整體而言，這些型態的預測力與預測期間成反比，在中型股的表現優於預測大型股。

邱科毓(2014)以台灣 50 成分股為標的，於 2004 年 1 月至 2013 年 9 月回測均線交易策略，其買進訊號設定為以下三個條件：

1. 9 日威廉指標 $>70$
2. 5, 20, 60 日均線之最大最小值差/中間值  $\leq x\%$ (參數)
3. 股價出現實體中長紅 K(上漲  $y\%$ )

結果顯示，其中有 42 支股票的累積報酬為正，比例達 87.5%，整體平均累積報酬為 121.7%，優於加權指數的累積報酬 38.39%，證明該技術分析策略應用於台股能取得不錯的超額報酬。

陳炫燐(2015)以 2008 年至 2014 年台股期貨 1 分 K 的資料，對多空各十種的 K 線型態進行當沖交易回測，結果發現，在多頭型態中的槌子型態月平均報酬率能夠達到 8.48%，而空頭型態中以吞噬型態最為有效，月均報酬率可達 8.21%，證實 K 線型態應用於台股期貨市場之獲利性。

上述研究皆說明了不論是技術指標或是 K 線型態，技術分析確實有其獲利性；此外，在許多技術分析的研究文獻中，多使用移動平均線作為驗證技術分析有效性，而著名葛蘭碧八大法則亦教我們如何使用均線指標，本研究認為均線已在技術分析的範疇中佔了不可或缺的位置，因此後續考慮將其納入到本篇研究的交易策略中。

## (二) 籌碼分析

籌碼代表市場上每個交易者手上持股狀況，以供需理論而言，部位、資金較龐大的交易人對股價的走勢能產生決定性的影響，例如：董監事、大股東，以及機構法人…等等。目前已有文獻證實籌碼面對於股價報酬具有影響力：

Foster, Gallagher and Looi(2011)認為投資機構經理人具有資訊優勢，能夠先行布局以獲得較佳的報酬，在淺碟市場下此效應會更加明顯。透過分析 34 個澳洲主動型基金經理人於澳洲股市前 50 大股票的兩年交易紀錄、持股資料，顯示機構法人的買超與後續股票報酬確實呈現顯著正相關，亦發現股票報酬與基金風格有關，成長型基金傾向動能策略，同期股價報酬與其買賣呈正向關係；平衡型及價值型偏好逆勢策略，同期報酬與其買賣呈負向關係。

Ferreira, Matos, Pereira and Pires(2009)使用 2000-2010 年，32 個國家的資料，研究當地機構法人和外國機構法人的績效表現，結果顯示，平均而言外國

機構法人與當地機構法人沒有顯著差異，兩者持股皆與未來股價報酬成正相關，然而在資訊較不對稱、非英語系和無投資人保護的市場，當地機構法人具備較顯著的優勢。

Zheng, Li and Zhu(2015)在 2002-2012 年中國股市的研究中發現，不論是長期(年、季)或是短期，機構法人的從眾行為皆與股票未來超額報酬呈現正相關，法人群聚買進愈多，後續超額報酬愈高，法人群聚賣出愈多，後續超額報酬愈低，可能的原因來自於規模較小的機構法人和散戶投資者會追隨大型機構法人的買進，進一步推升股價使得股價出現超額報酬。此外，從眾效應對於不同的投資組合有不一樣的效果，機構法人的從眾行為對於高市值和流動性高的個股，效果強但影響時間短，對於市值較小、高成長或是流動性高的個股，雖然效果較微弱，但影響時間較久。

陳彥豪(2002)研究 1995-2001 年的投信與外資於電子股的持股狀況，發現法人持股比率與電子指數有顯著高度正相關，而本益比與持股比例亦呈現中度正相關，代表其投資策略傾向留強汰弱。法人的持股率和個股報酬率亦呈顯著正相關，意味法人龐大資金的買進賣出對股價帶來強勁的支撐和壓力，其中投信對於短期股價的影響力顯著大於外資。透過投資組合模擬，法人持股較高或買超較大的個股所形成的投資組合，中長期而言，其報酬率顯著優於加權指數報酬。

劉瑞祥(2016)以 2002-2005 年台股外資及投信的交易明細為樣本，研究法人之買賣行為，結果顯示，兩者在買進、賣出皆有顯著的從眾行為，其中外資法人最為明顯，其賣出股票時會參考投信的賣出行為，亦會追隨其他同類型法



人。在報酬部分，外資群聚買進對於下一季報酬有正向影響，而投信法人的群聚賣出則對下一季報酬有負面影響。

可以從上述研究看到，不論是中國、澳洲、台灣或是其他國家的股票市場，多數存在著法人的從眾行為，這樣的現象使得法人持股與未來報酬呈現正相關，本研究將進一步設計籌碼指標，進而捕捉上述的現象，在法人布局初期，搶先進場。

### (三) 基本分析

巴菲特(Warren Buffett)為使用基本分析最具代表性的投資大師，其核心理念在於：評估公司是否有足夠的利基、合理的財務狀況，進而買進股價遭到低估的公司。這樣的投資方式在 1956 年至 1969 年為他帶來年均 30% 以上的報酬，至今依然維持著優異的績效，根據 2018 富比士世界富豪榜，巴菲特的淨資產來到 840 億美元，高居第三名，可說是最成功的投資人之一。因此國內有許多研究將巴菲特的投資理念應用於台股的量化投資策略，李雅璇(2013)將巴菲特選股法則量化，進行初步選股，再以獲利能力、經營績效、償債能力，以及經營能力此四個面向的財務狀況，進行第二階段的篩選，結果顯示 2002 年至 2012 年的年化報酬達到 18.1%，績效顯著優於大盤。

除了巴菲特的選股法則，Piotroski(2002)提出了 F-score 選股模型，透過財報建立九項指標，如下：

1. 當年度獲利  $> 0$
2. 當年度營業現金流  $> 0$
3. 當年度營業現金流  $>$  當年度淨利
4. 當年度長期負債金額  $<$  上一年度長期負債金額
5. 當年度流動比  $>$  上一年度流動比

6. 上一年度無發行新股
7. 當年度總資產報酬率  $>$  上一個年度總資產報酬率
8. 當年度毛利率  $>$  上一年度毛利率
9. 當年度資產週轉率  $>$  上一年度資產週轉率

符合指標即得 1 分，每年定期買進總分數高且高帳市值比的股票，並放空總分數低的股票，在 1976 年至 1996 年的美國股市中能得到 23% 的年化報酬，顯示透過財報即能建立簡而有力的選股策略。

賴靖宜等學者(2011)將 F-score 的選股架構應用於台灣股市，並且因應台灣產業特色，將指標根據產業平均進行調整，此外亦加入盈餘與營收穩定性指標、現金比率指標及董監事持股比率指標形成 S-score，結果顯示，考量風險後的報酬，S-score 表現優於 F-score。

陳渝雯(2017)以 2008-2016 年的台灣上市股票，進行 Fama French 三因子模型的實證，結果顯示，各因子能顯著解釋投資組合的超額報酬，模型解釋力達到 90.35%，驗證三因子模型應用於台灣股市的可行性。此外，該研究將個股報酬整合為產業報酬，檢驗三因子模型之顯著性，發現不同產業報酬存在相當程度顯著性的差異，顯示產業因子對於投資組合具備一定的重要性。

饒瑞鵬(2006)以 1999-2004 年台股資料作為樣本，使用基本面指標(益本比、股價淨值比、股利殖利率)、公司獲利能力(稅後純益、營業成長率)及籌碼指標(外資持股率、融資利用率)，並以相關係數加權形成投資價值指標。結果顯示，各個投資組合相對指數皆能產生超額報酬，多數的報酬來自於助長性，大盤轉強時，投資組合能有更高的 Beta。

陳彬洲(2015)以 2002-2012 間台股的台灣 50 及中型 100 的成分股作為研究對象，探討基本面、籌碼面及總經面因子對於股票報酬的影響。結果顯示，總資產報酬率與報酬率呈現顯著正相關，每股盈餘和負債比率與股票報酬並無顯著相關；籌碼面部分，法人買賣超及融券餘額和報酬率成顯著正相關，而散戶指標－融資餘額和股票報酬並無顯著關係。

在基本面的文獻，能看到經典、大師級的選股策略，亦能看到因子模型的研究，包括產業面的因子、總經因子、綜合基本面因子，而本篇研究會從最根本的財報資訊中，自行開發一套基本面因子的策略。

## 第二節 深度學習

Vanstone, Finnie and Hahn(2011)參考 C.D. Aby, Briscoe, N. R., Elliot, and R. S. Bacadayan(2001)所提出的 4 項基本面指標選股法則，如下：

1. 本益比  $\leq 10$  倍
2. 市價  $\leq$  淨值
3. ROE(股東權益報酬率)  $> 12\%$
4. 股利發放率  $< 25\%$

並以澳洲前 200 大公司做為研究對象，將此 4 個指標轉為特徵資料，使用標準化將值壓縮於 0-1 之間，而標籤值為後 200 日的最高報酬率，輸入類神經網絡進行訓練，結果顯示績效普遍優於原先的選股策略。

Sezer, Ozbayoglu and Dogdu(2017)以 1997/01-2006/12 的道瓊指數成分股日資料做為訓練資料，計算技術指標移動平均線(MA)與相對強弱指標(RSI)，移動平均線判斷趨勢，相對強弱指標決定買賣，並使用基因演算法尋找出獲利最大的參數組合，接著將這些參數組合給予買進、賣出、持有的標籤，最後將這些

資料輸入深度類神經網絡進行訓練，結果顯示在樣本外期間(2007/01-2017/01)模型的績效優於買進持有。

黃鐘億(2008)以 2006-2007 年間的台股周頻及日頻資料，使用倒傳遞類神經網路建構預測台灣 50 報酬率之模型，在變數選擇上，除了使用 7 項技術指標作為變數外，該研究亦使用了領先成分股、波動度、逐步回歸與隨機法篩選出 20-30 個重要的股票作為變數輸入模型訓練，在模型績效評估部分，若模型預測下期報酬率為正，而實際報酬率亦為正，則代表該次預測正確。結果顯示，技術指標作為變數，使用 Levenberg-Marquardt 的倒傳遞類神經網絡模型，測試期命中率能夠達到 95% 以上，亦有較穩定的預測能力，此結果亦說明了技術指標相對於成分股更適合作為預測台灣 50 報酬率之變數。此外，該研究亦比較了變數挑選前後的表現，結果顯示，變數經過適當篩選後，能夠同時提升命中率及穩定度。

查欣瑜(2011)使用 2007-2010 台指期及選擇權資料，訓練類神經網絡模型預測台指期未來漲跌，輸入的變數主要為法人籌碼資訊(期貨、選擇權未平倉部位、現貨買超金額、多空未平倉平均權利金…等等)，並將這些資訊進一步計算，延伸出一階變量和二階變量，此法參考 Chen and Hsu(2010)所建議的，類似物理學的速度與加速度，能夠提升模型學習的效果。結果顯示，在訓練樣本中，該模型預測 1/3/5 天報酬皆有良好的表現，準確率皆能達到 70% 以上，然而在測試樣本中，預測 1 天及 3 天的模型表現大幅下降，但預測 5 天的模型仍然可以維持 70% 以上的準確率，代表法人籌碼對於極短期的影響並不特別明顯，時間稍微延長能夠明確看出法人籌碼與股價趨勢呈正向關係。

曲恬頤(2009)分別建立決策樹選股模型及類神經網絡預測股價模型，在決策樹選股模型的部分，該研究使用過去一年的財報資料預測下一年股價的強弱程度，分別為 A 相對強勢/B 相對稍強/C 相對稍弱/D 相對弱勢，比較基準為大盤指數，此作法能夠去除景氣循環因素，選出股票後再濾除成交量不足之個股，結果顯示，買進 A 組合放空 D 組合能夠在 2008 年間大盤下跌 38.65% 時，取得 8.35% 的低風險報酬；在類神經網絡預測股價模型的部分，該研究使用 16 項技術指標(移動平均線、量能指標、擺盪指標…等等)及法人買賣超、券資比等，共 33 個輸入變數，預測下一期股價之開、高、低、收，結果顯示，依照預測訊號交易能夠在 2008 年大盤下跌期間取得 6.95% 的正報酬，且勝率大於 50%。最後，該研究將兩策略進一步結合，買進強勢股，同時放空弱勢股，最佳的表現能夠達到 47.63% 總報酬。

由於本研究在第三章所使用的深度學習模型是最基本的 DNN 模型，架構上會與類神經網絡相似，所以此節會參考關於類神經網絡的文獻，瞭解各篇研究在訓練模型上的發現，並學習他們的優點。

## 第三章 研究方法

### 第一節 實驗架構

本研究實驗架構如圖 3-1 所示，首先進行資料蒐集，取得三大分析所需的財務報表、法人籌碼以及每日股價資料，整理資料並計算所需指標，接著分別建構基本、法人籌碼與技術分析策略。在基本策略的部分，將使用深度學習訓練模型，透過財報中眾多特徵的訓練，尋找下一季相對強勢的股票。技術面與籌碼面策略的部分，由於股票價格與法人買賣資訊皆為日頻資料，因此本研究結合此兩大分析的指標，以不同的面相補足各自的缺點，建構出擇時策略。最後將上述兩策略結合，每一季的季末(財報最後公布日)以基本面策略選出的股票作為股票池，再依技術面與籌碼面策略產生的訊號進行擇時進出場，此為本研究的最終目標－三大分析之深度學習交易策略，並進一步評估績效，檢驗策略之獲利性、穩定性。

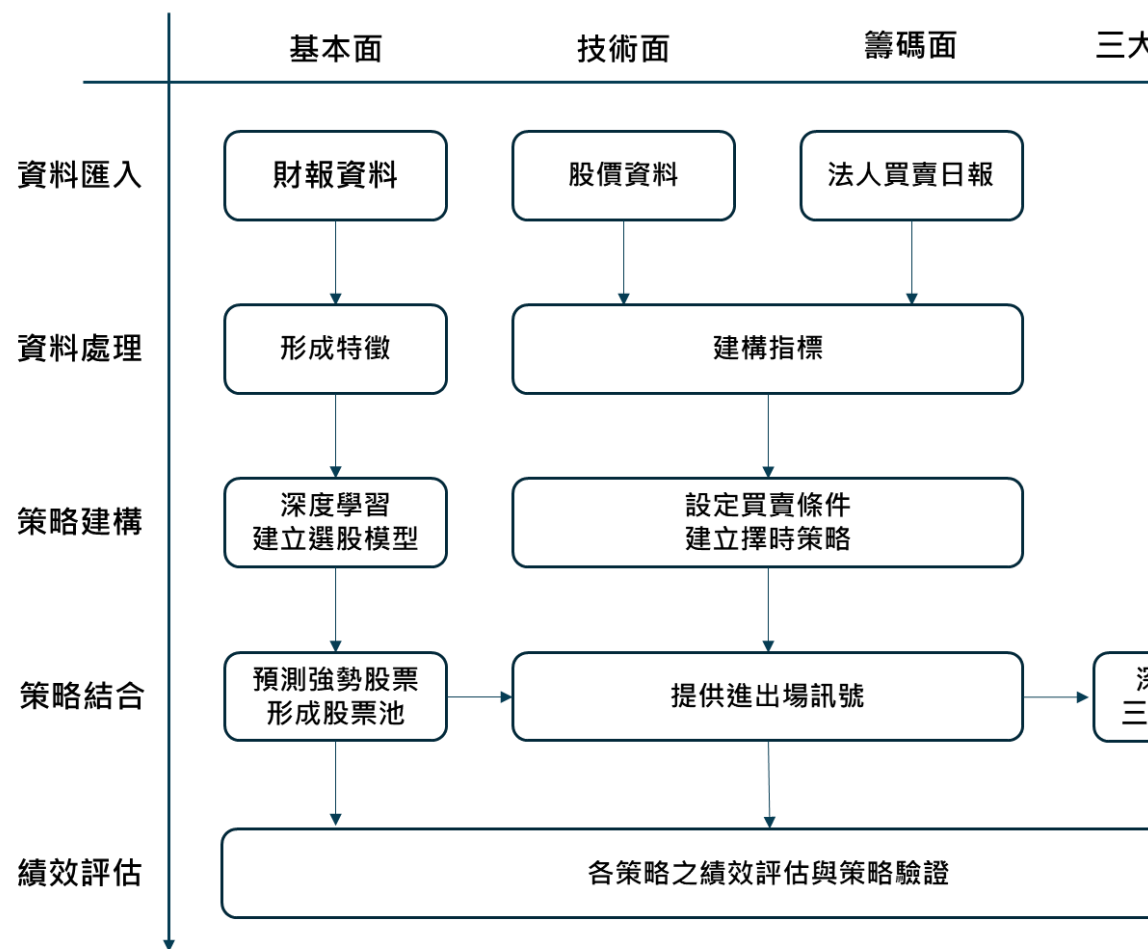


圖 3-1 實驗架構圖

## 第二節 資料蒐集與建立

本研究選擇標的為所有台灣股市上市櫃公司，為避免有倖存者偏差 (survivorship bias)，亦將下市櫃公司納入。資料來源為台灣經濟新報資料庫 (TEJ)，財報資料的樣本期間為 2003Q4 – 2017Q3，共 56 季；每日股價資料為 2004/03/01 – 2017/03/01，共 13 年，總計 2013 檔股票，4,792,302 筆資料，本研究以未調整股價計算技術指標，因為未調整股價為每日市場最即時、真實的資訊，市場參與者多以此作為判斷依據，而評估策略報酬時則以調整後股價進行計算，由於買賣股票的報酬計算方式如下

$$\begin{aligned} \text{ROI} &= \text{資本利得} + \text{股利所得} \\ &= \frac{P_{\text{sell}} - P_{\text{buy}}}{P_{\text{buy}}} + \frac{\text{Dividend}}{P_{\text{buy}}} \end{aligned} \quad (3.1)$$

其中  $P_{\text{buy}}$  為買進價格， $P_{\text{sell}}$  為賣出價格，而未調整後股價並無考量到除權息的狀況，因此調整後價格為未調整價格還原權息後之值，因此在計算評估策略報酬時，可將公式(1)以下式取代

$$\text{ROI} = \frac{P_{\text{sell}}^{\text{adj}} - P_{\text{buy}}^{\text{adj}}}{P_{\text{buy}}^{\text{adj}}} \quad (3.2)$$

$P^{\text{adj}}$  代表調整後的買進與賣出價格，本研究亦將交易成本納入考量，以貼近現實交易狀況，買進賣出手續費皆以最高上限 0.1425% 計算，證券交易稅 0.3%，考慮交易成本後報酬率如下

$$\text{ROI} = \frac{P_{\text{sell}}^{\text{adj}} \times (1 + 0.4425\%)}{P_{\text{buy}}^{\text{adj}} \times (1 + 0.1425\%)} - 1 \quad (3.3)$$



在籌碼面的部分，台灣經濟新報資料庫提供的三大法人籌碼資料，樣本期間為 2008/01-2018/03。資料彙整如表 3-1

表 3-1 三大分析所需資料

種類	資料內容
基本面	資產負債表、損益表、現金流量表等部分項目
	台灣經濟新報資料庫所計算之財務比率： 流動比、速動比、長期資金適合率、利息保障倍數、利息支出率、每股盈餘、研發費用率、總資產周轉率、應收帳款周轉率、存貨周轉率、固定資產周轉率、權益周轉率、應收帳款佔營收比、存貨佔營收比、股價淨值比、本益比、股利殖利率、現金殖利率
技術面	每日調整後股價：開盤價、最高價、最低價、收盤價、成交量、成交值
	每日未調整股價：開盤價、最高價、最低價、收盤價、成交量、成交值
籌碼面	外資、投信、自營商每日買賣超

\*本研究自行整理

資料來源：TEJ

### 第三節 量化策略建構

#### (一) 深度學習結合基本分析策略

每季結束後公司便會在特定期間內發布財務報告，該報告代表最新營運狀況的變化，勢必影響後續的股價，本研究將藉由深度學習之模型從每季 1700-1800 份的財報資訊中，尋找下一季表現較為強勢的股票。以下分幾個步驟依序說明：

##### 步驟(一) 選擇財報特徵

財報中有許多項目，此步驟將決定哪些項目要納入參考範圍，由於所有公司要同時進行比較，因此原則上選取基礎、常見的項目以及實務上投資人選股常使用的指標，共 129 項指標(完整表格請參考附錄一)，以下分幾個大項目進行說明。

##### 1. 財務結構

本研究從資產負債表中選擇企業營運中常見的項目，包括現金、存貨、應收帳款、固定資產、流動負債、長期負債、總負債、普通股股本、特別股股本、總權益，由於各家公司資產規模不一，因此將這些項目以總資產金額進行標準化，如同財報分析方法所使用的共同比分析，以現金為例，該項目轉換方式如下式

$$\text{Cash}_{\text{new}} = \frac{\text{Cash}}{\text{Total Asset}} \quad (3.4)$$

透過轉換後，能夠知道目前企業的財務結構，而結構的轉變亦相當重要，因此本研究新增了季變動和年變動，如同財報分析方法中的比較分析，以現金項目季變動為例，計算方式如下

$$\text{Cash}_{\text{季變動}} = \frac{\text{Cash}_{\text{本季}}}{\text{Total Asset}_{\text{本季}}} - \frac{\text{Cash}_{\text{上季}}}{\text{Total Asset}_{\text{上季}}} \quad (3.5)$$

有別於一般成長率相除的算法，此算法能考慮到變動的規模，舉例來說，A 公司的現金佔資產比率本期為 10%，下期為 20%，而 B 公司本期為 2%，下期為 4%，若以相除的算法，A 和 B 的現金比例皆成長 100%，但若以公式(3.5)計算，A 為 10%，B 為 2%，A 與 B 變動規模之差距便顯而易見，此為本研究採用公式(3.5)的原因。總結此部分共使用了 30 個指標，彙整如表 3-2

表 3-2 財務結構指標

財務結構指標
現金比率
應收帳款比率
存貨比率
固定資產比率
流動負債比率
長期負債比率
總負債比率
普通股股本
特別股股本
總權益

\*本研究自行整理

## 2. 損益狀況

此部分主要來自於損益表之項目，彙整如表 3-3，由於每家企業規模不同，因此營收及盈餘以每股的方式進行比較。毛利、營業利益、EBIT(Earning Before interest and tax，稅前息前盈餘)及稅後淨利則是採用營收轉換為百分比率進行比較，而表中較特別的是營業集中度，以繼續營業單位稅前淨利佔營業利益比重衡量公司業外損益佔比是否過大，公式如下：

$$\text{營業集中度} = \frac{\text{繼續營業單位稅前淨利}}{\text{營業利益}} \quad (3.6)$$

此外也納入投資人在評估企業獲利能力的重要指標，ROE(股東權益報酬率)以及 ROA(總資產報酬率)。一般企業發布財報時，常以年初累積至今的方式呈現損益表，本研究額外計算單季與近四季的數據，檢視企業過去一季的營運成果，以及過去一年損益概況，此外季增率和年增率的指標亦是趨勢分析的重點，所有指標整體計算後，共有 78 項，以多面向檢視企業獲利狀況，讓機器藉由不同項目、時間的特徵，提升模型分辨出強弱勢股票的可能性。

表 3-3 損益指標

損益指標		
累計每股營收	單季營業集中度	
單季每股營收	累計 EBIT	
近四季每股營收	單季 EBIT	
累計毛利率	近四季 EBIT	
單季毛利率	累計稅後淨利率	
近四季平均毛利率	單季稅後淨利率	
累計營業利益率	近四季稅後淨利率	
單季營業利益率	累計每股盈餘	
近四季平均營業利益率	單季每股盈餘	
累計營業集中度	近四季每股盈餘	

註：每一項目均會計算出季變動和年變動

### 3. 其他財務指標

此部分包含衡量公司經營績效的指標，例如各項週轉率，週轉率越高，企業經營能力相對較好，也有評估償債能力的指標，例如利息保障倍數、流/速動比，當企業有足夠盈餘支付財務費用時，可以額外拓展營運規模，為公司成長帶來動能，而金流之穩定性，如自由現金流量能評估公司會不會有周轉不靈的危機。總結而言，共計 21 項，為本研究認為可能影響公司未來報酬的財務指標，彙整如表 3-4

表 3-4 其他財務指標

其他財務指標	
流動比率	(季底) 股價淨值比
速動比	(季底) 本益比
長期資金適合率	(季底) 市值
利息保障倍數	(季底) 應收帳款佔營收比重
利息支出比率	(季底) 存貨佔營收比重
未分配盈餘	自由現金流量佔總資產比率
研發費用率	股利殖利率
總資產周轉率	現金殖利率
應收帳款周轉率	
存貨周轉率	
固定資產周轉率	
權益周轉率	
應付帳款付現天數	

\*本研究自行整理

## 步驟(二) 以深度學習建立選股模型

深度學習為機器學習的其中一種，讓機器根據訓練資料，尋找出潛在規則，進而做出預測。深度學習模型的架構是由多層類神經網絡所組成，模擬生物的神經網絡運作方式。生物的神經系統是由神經元連接而成，當神經元接收到的訊號量超過某個閾值時，便會產生電流，藉由突觸將資訊傳遞到下一個神經元，而機器透過激活函數模擬神經元的運作，如圖 3-2，特徵向量

$x_1, x_2, x_3, x_4$  進入神經元之前會被賦予對應的權重  $w_1, w_2, w_3, w_4$ ，兩者內積後加上常數項  $b$ ，將此結果帶入激活函數  $f(x)$  得到輸出值，激活函數常是非線性函數，用於處理非線性問題，目前常見的激活函數為 relu (rectified linear unit, ReLU)，如下式：

$$f(x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases} \quad (3.7)$$

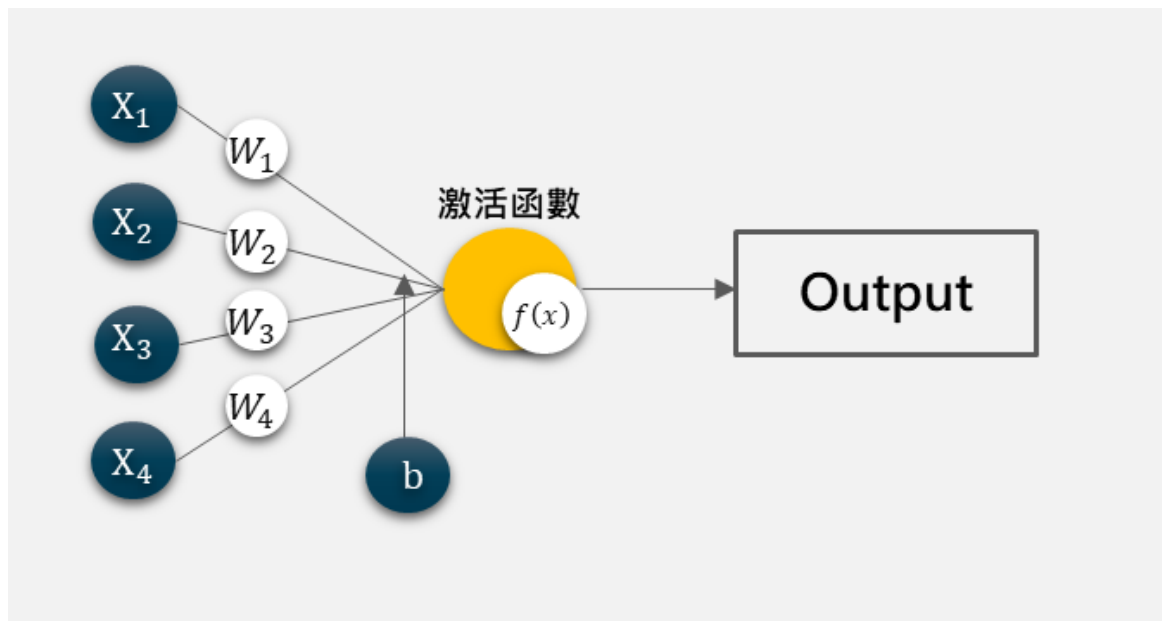


圖 3-2 單一神經元結構示意圖

\*本研究自行整理

上述即為一個神經元的運作方式，將各個神經元連接起來便形成了類神經網絡，而藉由深層的設計，如同生產線一般，使得整體的學習過程更有效率，亦能因應不同的需求產生模型架構，例如：處理時間序列的長短期記憶模型

(long short-term memory, LSTM)。有了神經系統的架構，透過損失函數評價每組參數產出結果的優劣，並使用梯度下降法和反向傳播法調整參數，在每輪訓練中微調參數，直到無法找到更好的參數則停止，這樣的過程使得機器具備了類似學習的能力，如同人類藉由歷史經驗、錯誤不斷地學習、調整自我。

梯度下降法(Gradient descent)能夠幫助模型有效率地尋找參數最佳解，此處以線性回歸為例：

1. 設定函數，線性回歸的函數如下

$$h_{\theta}(x) = \theta_0 + \theta_1 x \quad (3.8)$$

2. 設定損失函數(Cost function)

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \quad (3.9)$$

3. 目標為最小化 $J(\theta_0, \theta_1)$ ，在可微分的情況下，對 $J(\theta_0, \theta_1)$ 求偏導數：

$$\begin{aligned} \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} &= \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x - y) \\ &= \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x) - y) \end{aligned} \quad (3.10)$$

$$\begin{aligned} \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} &= \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x - y) x^{(i)} \\ &= \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x) - y) x^{(i)} \end{aligned} \quad (3.11)$$

4. 設定 $\theta_0$ 、 $\theta_1$ 初始值，不斷更新參數並計算誤差，直到誤差收斂即停止

$$\theta_0 := \theta_0 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} \quad (3.12)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} \quad (3.13)$$



然而一個類神經網絡模型比線性回歸模型複雜許多，必須藉由反向傳播法 (Back Propagation) 來快速計算每個神經元的梯度，本研究引用 MacLeod, Christopher(2015). “An Introduction to Practical Neural Networks and Genetic Algorithms for Engineers and Scientists”. 當中第三章所提及反向傳播法的公式推導，示意圖如圖 3-3。

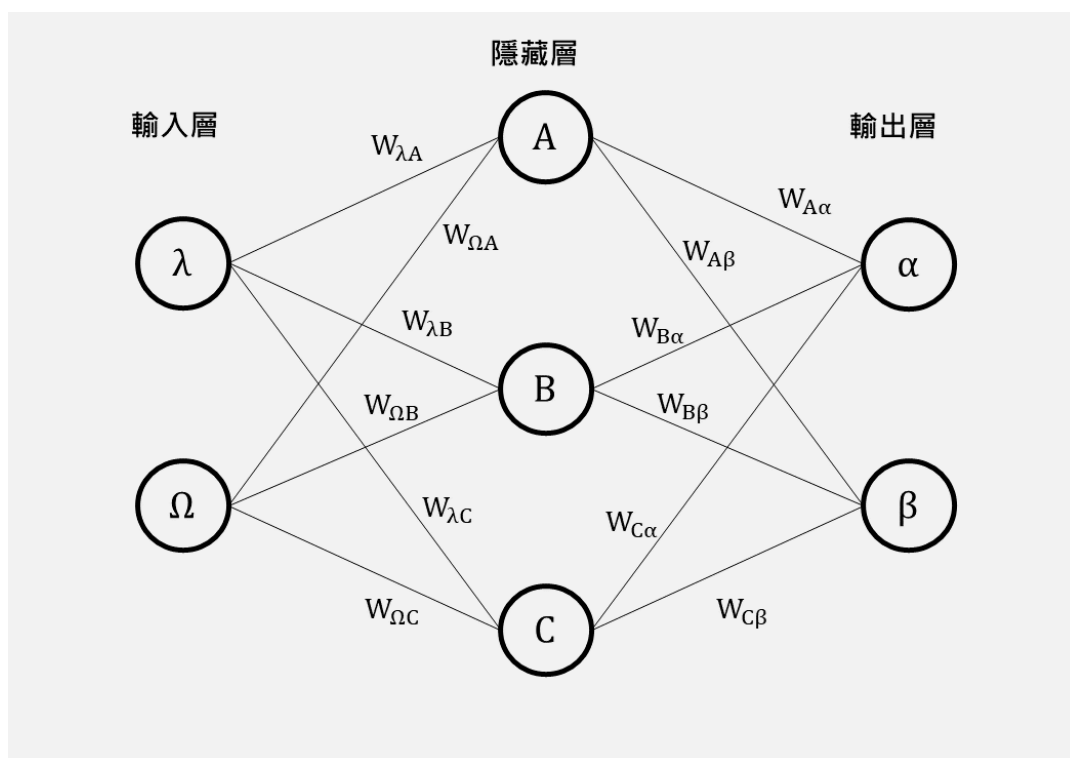


圖 3-3 單層類神經網絡示意圖

每個輸入神經元的值皆有對應的權重，為可調整的參數，其調整步驟如下：

1. 計算輸出層輸出誤差(假設激活函數為 Sigmoid function)

$$\delta_{\alpha} = \text{Out}_{\alpha}(1-\text{Out}_{\alpha})(\text{Target}_{\alpha}-\text{Out}_{\alpha}) \quad (3.14)$$

$$\delta_{\beta} = \text{Out}_{\beta}(1-\text{Out}_{\beta})(\text{Target}_{\beta}-\text{Out}_{\beta}) \quad (3.15)$$

## 2. 更新輸出層權重

$$W_{A\alpha}^+ = W_{A\alpha} + \eta\delta_\alpha \text{Out}_A \quad W_{A\beta}^+ = W_{A\beta} + \eta\delta_\beta \text{Out}_A \quad (3.16)$$

$$W_{B\alpha}^+ = W_{B\alpha} + \eta\delta_\alpha \text{Out}_B \quad W_{B\beta}^+ = W_{B\beta} + \eta\delta_\beta \text{Out}_B \quad (3.17)$$

$$W_{C\alpha}^+ = W_{C\alpha} + \eta\delta_\alpha \text{Out}_C \quad W_{C\beta}^+ = W_{C\beta} + \eta\delta_\beta \text{Out}_C \quad (3.18)$$

## 3. 計算隱藏層輸出之誤差(反向傳播)

$$\delta_A = \text{Out}_A(1-\text{Out}_A)(\delta_\alpha W_{A\alpha} + \delta_\beta W_{A\beta}) \quad (3.19)$$

$$\delta_B = \text{Out}_B(1-\text{Out}_B)(\delta_\alpha W_{B\alpha} + \delta_\beta W_{B\beta}) \quad (3.20)$$

$$\delta_C = \text{Out}_C(1-\text{Out}_C)(\delta_\alpha W_{C\alpha} + \delta_\beta W_{C\beta}) \quad (3.21)$$

## 4. 更新隱藏層權重

$$W_{\lambda A}^+ = W_{\lambda A} + \eta\delta_A \text{In}_\lambda \quad W_{\Omega A}^+ = W_{\Omega A} + \eta\delta_A \text{In}_\Omega \quad (3.22)$$

$$W_{\lambda B}^+ = W_{\lambda B} + \eta\delta_B \text{In}_\lambda \quad W_{\Omega B}^+ = W_{\Omega B} + \eta\delta_B \text{In}_\Omega \quad (3.23)$$

$$W_{\lambda C}^+ = W_{\lambda C} + \eta\delta_C \text{In}_\lambda \quad W_{\Omega C}^+ = W_{\Omega C} + \eta\delta_C \text{In}_\Omega \quad (3.24)$$

其中常數  $\eta$  為學習速率，可根據訓練過程進行調整

本研究欲利用深度學習尋找下一季相對強勢之股票，此部分採用監督式學習，如同建立回歸模型一般，輸入每一組 X，需有對應的 Y，因此輸入深度網絡模型的 X 為步驟一選出的 129 個財報特徵，Y 為下一季的股票報酬率。在研究過程中，發現將 X 與 Y 進行標準化轉換有助於模型的訓練，因此對於每一項特徵 X，及股票報酬 Y 轉換為 0-1 之間的常態累積機率，如下式

$$Zscore_{x_i} = \frac{x_i - mean(x)}{sd(x)} \quad (3.25)$$

$$x_i := P(Z < Zscore_{x_i}) \quad (3.26)$$

此外，若將特徵進一步篩選再輸入深度網絡訓練，不僅有可能提升模型的表現，亦可降低訓練時間，此作法如同黃鐘億(2008)先將各變數藉由不同的方法篩選出來，使得模型具備較佳的準確性與穩定性，本研究的特徵選取作法如下

- (一) 計算每個特徵過去 8 季與次季報酬的相關係數
- (二) 將相關係數進行累加，可得到 8 個值
- (三) 計算此 8 個值的趨勢線
- (四) 該特徵的分數 = 趨勢線斜率 × 最近一季相關係數累積值
- (五) 取出分數前 30 高的特徵

處理完特徵資料後，接下來進行深度網絡模型的設定，使用的架構為深度神經網絡(Deep Neural Network，DNN)，亦稱作多層感知機(Multi-Layer perceptron，MLP)，本研究設定每層神經元數量的邏輯為：一開始的數量為輸入特徵的數倍，接下來逐層遞減，最後收斂至 1 個為輸出結果。細節設定如表 3-5

表 3-5 深度學習模型設定

項目	設定
網絡架構	DNN
輸入特徵	30 個
隱藏層數量	4 層
各隱藏層神經元數量	256/128/64/32
激活函數	Relu
損失函數	MSE
優化器	adam
Batch size	128
epoch	20

\*本研究自行整理

### 步驟(三) 設定樣本回測方式

本研究採用滾動樣本方式進行回測，每隔一季便更新過去 8 季資料訓練模型，再以本季財報資料做預測，以保持模型的有效性；另一方面，由於財報樣本有 56 季，共能產生 47 個模型，因此能透過這些模型的表現驗證此策略之穩健性。為符合真實交易之合理性，本研究將最新一季財報資料的取得時間一律調整為最後公布日，而 2013 年第一季起採用 IFRSs，因此前後日期稍有不同，調整日期如表 3-6，這些日期為模型更新時間，產生新的預測後，隔一交易日開盤進場。基本面選股策略流程彙整如圖 3-4

表 3-6 財報最後公布日

季度	2013Q1 前(GAAP)	2013Q1 後(IFRSs)
Q1	4/30	5/15
Q2	8/31	8/14
Q3	10/31	11/14
Q4	3/31	3/31

\*本研究自行整理



圖 3-4 滾動樣本回測示意圖

## (二) 技術與籌碼分析策略

此策略買賣條件的設定將會從簡，結合實務與理論設計條件，避免使用太多複雜的條件或參數導致過擬合(Overfitting)，以下就技術分析、籌碼分析分別進行策略進出場條件設計的說明。

### 1. 技術分析

在過去的文獻中，簡單移動平均線為最常見也是最有價值的指標之一，其計算方法如下

$$SMA_n = \frac{close_t + close_{t-1} + \dots + close_{t-n+1}}{n} \quad (3.26)$$

許多文獻中的應用皆是使用短期均線與長期均線黃金交叉作為買點，此為葛蘭碧八大法則的概念之一，但在此策略中，不使用黃金交叉當買點，而是將它做為買進條件的輔助條件之一，如下

$$buy\_condition_1 = SMA_{short} > SMA_{long} \quad (3.27)$$

本研究將短期均線設定為 5 日均線，為投資人常用的短期指標，代表近一周成交狀況，而長期平均線設定為 60 日均線，實務上稱作季線，反映股價長期趨勢，此參數亦是配合基本面選股更新的頻率，使得最後整體策略能夠適當結合。葛蘭碧八大法則除了運用穿越尋找買賣點外，其另一個核心概念為均線的上揚與下彎，它能夠助長趨勢的有效性，因此本研究加入長期均線上揚這個買進條件，如下

$$buy\_condition_2 = SMA_t^{long} > SMA_{t-1}^{long} \quad (3.28)$$

總結技術分析的買進條件，短期均線 > 長期均線代表短期投資人追價意願強於長期投資人，後續上漲時賣壓較小；長期均線的上揚顯示長期投資人持續買進，成本墊高，有助後續漲勢；而長短期參數的設定則是考量到時間周期的意義性，例如：年、半年、季、月、周，同時亦考慮到市場投資人使用的普及程度，因此這些參數不僅代表股價的趨勢，也代表著市場的心理。而技術分析出場條件的設定則是對應買進訊號，如下

$$sell\_condition_1 = SMA_{short} < SMA_{long} \quad (3.29)$$

短期均線一樣為 5 日線，長期均線由 60 日線改為 20 日線，由原先的季線換為月線，原因在於本研究認為當 5 日線跌破月線後，短期上漲趨勢將告一段落，甚至有可能繼續往季線支撐移動，因此提早出場以保護獲利和降低虧損，亦可將資金轉移至其他發出買進訊號的股票。

## 2. 籌碼分析

在三大法人的交易資訊中，淨買賣是最常被使用的項目之一，本研究進一步將淨買賣除上交易量用以衡量法人買賣超的力道，如下

$$\text{法人買賣超力道} = \frac{\text{過去 5 日法人淨買賣}}{\text{過去 5 日交易量總和}} \quad (3.30)$$

本研究認為法人買賣力道的參考性依序為：投信 > 自營商 > 外資，原因在於，外國機構法人買賣台灣股票之目的除了獲利之外，尚有配合期貨操作、匯率升貶、大型指數編製等影響，相比之下本土投信和自營商的操作目的較為單純，以獲得超額報酬為主，在中小型股票選股上，亦有在地資訊優勢，因此本研究以投信買賣力道建構籌碼分析進場條件，並以外資和自營作為對照組，籌

碼分析進場條件如下

$$buy\_condition_3 = \text{投信買賣力道}_t \text{ 穿越 } 5\% \quad (3.31)$$

其中穿越的意思為第  $t$  期大等於 5% 且  $t-1$  期小於 5%，此條件代表的意義為當投信在過去一段時間內開始積極布局該檔股票，後市股價表現可期。與技術分析的設定相同，此部分亦有相對應的出場條件，如下

$$sell\_condition_2 = \text{投信買賣力道}_t \leq -2.5\% \quad (3.32)$$

當投信過去一段時間賣出股票的力道放大時，代表未來股價極有可能受到抑制，此條件參數設定則是對應買進條件(3.31)的參數 5%，乘上 0.5 使得賣出條件較敏感，能夠預先保護獲利，同時搭配技術面賣出條件(3.29)，能夠讓賣出訊號不會過度頻繁出現，導致不必要的虧損以及無法取得大波段的獲利。

總結技術結合籌碼分析的策略，進出場訊號整理如表 3-7，整體交易邏輯為：技術面強勢，籌碼面買超力道放大時進場，當技術面轉弱，籌碼面亦呈現較大賣超則出場，透過不同面向的重複確認能夠降低訊號錯誤率，提升策略報酬。在參數設定上，本研究採用有時間周期意義且能夠使策略互相呼應之參數，如：基本面選股為每季選一次股票，技術面進場條件中的長期均線參數則設定為 60 日，代表一季的交易天數，如此設定使得兩策略的操作頻率較相近，讓後續的結合不僅較有意義外，更可能提升策略績效。



表 3-7 進出場訊號條件彙整

訊號	分析類別	條件	動作
進場訊號	技術分析	$SMA_t^5 > SMA_t^{60}$ $SMA_t^{60} > SMA_{t-1}^{60}$	隔日開盤進場
	籌碼分析	投信買賣力道 <sub>t</sub> ≥ 5% 投信買賣力道 <sub>t-1</sub> < 5%	
出場訊號	技術分析	$SMA_t^5 < SMA_t^{20}$	隔日開盤出場
	籌碼分析	投信買賣力道 <sub>t</sub> ≤ -2.5%	

\*本研究自行整理

### (三) 深度學習與三大分析策略

此策略為本研究最終目標，結合策略(一)與策略(二)，於每一季季底，依據基本面模型選出預測下一季分數 $\geq 0.5$ 且前 500 高的股票作為股票池，雖然分數愈高期望報酬愈高，但會導致與技術與籌碼策略結合後訊號過少，使得交易次數過少降低策略參考性，績效表現亦可能隨之下降。接下來以技術與籌碼分析的訊號進行擇時進出場，若買進訊號落在下一季，則該筆交易成立，持有股票後直到賣出訊號發生才執行賣出，並不會因為該季結束而清空部位。

## 第四節 績效評估指標

本研究將由兩個面向評估策略，第一個為平均績效分析，對每一個進出場所產生的報酬進行分析，第二個為基金績效分析，設定初始資金，依照訊號發生模擬交易，如同基金一般，並對其所產生的報酬進行分析，以下分別說明其績效評估指標，皆扣除交易成本。

### (一) 平均績效評估指標

$$1. \text{ 平均報酬率} = \frac{\sum \text{每筆交易產生的報酬}}{\text{總交易筆數}} \quad (3.33)$$

$$2. \text{ 勝率} = \frac{\text{報酬} \geq 0 \text{ 的交易筆數}}{\text{總交易筆數}} \quad (3.34)$$

$$3. \text{ 獲利因子} = \frac{\text{報酬} \geq 0 \text{ 的平均報酬}}{|\text{報酬} < 0 \text{ 的平均報酬}|} \quad (3.35)$$

$$4. \text{ 平均持有期間} = \frac{\sum \text{每筆交易的持有天數}}{\text{總交易筆數}} \quad (3.36)$$

### (二) 基金績效評估指標

$$1. \text{ 年化報酬率} = (1 + \text{累積報酬率})^{\frac{1}{N}} - 1 \quad (3.37)$$

$$N = \text{投資期間(年)}$$

$$2. \text{ 最大回撤} = \text{投資期間至高點淨值回落的最大百分比} \quad (3.38)$$

$$3. \text{ 夏普比率} = \frac{R_p - R_f}{\sigma_p} \quad (3.39)$$

$R_p$  = 投資組合年化報酬率

$R_f$  = 無風險利率，以定存利率進行複利後計算年化報酬

$\sigma_p$  = 投資組合年化標準差

$$4. \text{ 平均資金閒置率} = \frac{\sum \left( \frac{\text{每日現金}}{\text{資產淨值}} \right)}{\text{總投資期間天數}} \quad (3.40)$$

此部分要特別注意的是，平均績效的評估方法是將各個交易紀錄產生的報酬率，視為獨立的交易來進行評估，基金績效則是自回測起始日設定初始資金，依照交易紀錄的排序依循買賣，進而計算淨值報酬率。此外，本研究亦將使用 t 檢定驗證策略是否具有顯著的超額報酬，或是兩策略間是否存在顯著差異。

## 第四章 實證結果

### 第一節 策略績效

#### (一) 深度學習結合基本分析選股

每季財報最後公布日會以過去 8 季資料，選出分數最高的前 30 個因子進入模型訓練產出新的模型，本研究將被選出來的因子統整於附錄(二)，接著並以本季財報資料進行預測，預測值多數會落在 0-1 之間，為探討此策略是否能夠辨別下一季強弱勢股票，本研究定義預測值  $\geq 0.5$  的股票為強勢股票，預測值  $< 0.5$  的股票弱勢股票，並且依照分數最高和最低各選出 500/300/100/50 檔，以等權重計算下一季報酬。透過強勢和弱勢組合報酬的相差，能夠看出此策略之選股能力，如圖 4-1，47 季回測期間，可以看到在各個檔數組合中，強勢組合普遍優於弱勢組合，若再進一步檢視各檔數組合的整體平均報酬差距，如圖 4-2，圖中報酬率隨著檔數下降而上升，由 500 檔的 3.67% 至 50 檔的 6.93%，代表預測分數差距越大，報酬差距越大，顯示此策略具有良好且穩定的選股能力。




圖 4-1 強弱勢各期報酬差距




圖 4-2 強弱勢整體平均差距

此外，將各個檔數組合的強弱勢報酬進行 t 檢定，假設如下

$$H_0: \mu_{\text{強勢}} \leq \mu_{\text{弱勢}}$$

$$H_1: \mu_{\text{強勢}} > \mu_{\text{弱勢}}$$

如表 4-1，各個檔數組合的 p 值皆小於 0.01，顯示強勢組合平均顯著優於弱勢組合，此結果如同上述的結論，再次驗證此策略具備良好的選股能力。

表 4-1 各組合強弱勢報酬 t 檢定結果

檔數組合	t 值	p-value
500 檔	6.0876	1.1E-07
300 檔	5.8843	2.2E-07
100 檔	5.7102	3.9E-07
50 檔	5.1348	2.8E-06

確認策略之選股能力後，接下來將策略進行基金化模擬實際交易情況，回測設定條件如下：

1. 初始資金：1 億元
2. 投資期間：2006/3/31(2005 年報最後公布日) - 2017/11/14
3. 投組建構：每季以等權重投資預測值 $\geq 0.5$  且分數前 500/300/100/50 高的股票，每季定期再平衡。
4. 假設無成交量限制，亦即目標買進股票數量市場皆能滿足。
5. 無風險利率為 2006-2017 的一年定存利率複利後的年化報酬：0.73%

回測結果如表 4-2，將近 12 年的回測，各個檔數組合皆能獲得 15% 以上的年化報酬，隨著檔數減少，年化報酬越高，這樣的關係與上述的發現不謀而合。而此基本面策略缺點在於最大回撤過高，在金融海嘯期間，各組合的最大回撤皆來到 60% 以上，可以在圖 4-3 看到 2008-2009 有明顯較大回撤，此外 2015 年中國股災亦受到較大的影響，不過其餘時間皆能隨著市場回升，持續創下報酬新高。整體而言，考量風險後的夏普值尚有 0.7 以上，也明顯優於買進持有台灣 50ETF，本研究認為此策略具備參考價值，亦證明深度學習運用於交易策略的有效性，與謝信誠(2017)機器學習能應用於金融領域的結論相呼應。

表 4-2 各組合基金績效

策略	累積報酬	年化報酬	最大回撤	Sharpe ratio
台灣 50ETF	142.41%	7.91%	58.87%	0.47
50 檔	661.17%	19.06%	65.07%	0.78
100 檔	628.16%	18.61%	64.48%	0.79
300 檔	484.09%	16.38%	65.01%	0.72
500 檔	463.03%	16.02%	65.46%	0.71




圖 4-3 各組合基金累積報酬走勢圖

## (二) 技術與籌碼擇時策略

此策略的建構來自於人為設定的條件，因無進行參數最適化，本研究認為無需切割樣本內樣本外，雖可能造成過度適配(Overfitting)之嫌，但藉由買賣條件背後的理論支持、合理的邏輯，以及大量的樣本數(2,013 檔股票/479 萬筆歷史資料)，能夠加強此策略之有效性，對於未來的交易具備參考價值。由於技術分析的設定均無改變，而籌碼指標因對照組而有所變動，以下使用法人的名稱代表技術結合籌碼分析的策略，表 4-3 為策略每筆進出場的平均績效，投信策略為本研究所提出的想法，外資及自營策略則為對照組。先看到投信策略的部分，以平均持有天數可以看出該策略為中期波段策略，平均報酬 3.41% 和 43% 的勝率屬合理範圍，獲利因子亦大於 1.5 顯示策略能夠有效獲取波段報酬並控制虧損，此外交易次數達 15,175 次為此策略優勢，樣本數量多能驗證此策略的有效性，同時能夠提升資金運用效率，因為各筆交易訊號的進出場時間會有重疊的效果，使得帳上閒置的現金能夠被運用，最後，充足的交易次數使得後續和基本面策略結合時，不致於缺少交易訊號。在對照組的部分，能夠看出投信策略在各方面皆優於外資與自營此二對照組。

表 4-3 技術結合籌碼策略平均績效

策略平均績效			
策略	投信	外資(對照組)	自營(對照組)
平均報酬	3.41%	1.64%	1.87%
勝率	43.02%	36.5%	37.9%
獲利因子	1.87	1.47	1.52
平均持有天數	50	43	44
交易次數	15,175	38,903	10,261



與上一部分的基本面策略相同，本研究將此策略的超額報酬進行檢定，而超額報酬的定義為單筆交易的報酬與持有期間標竿 ETF 的報酬相差，例如有一筆交易為 2015/10/01 進場，2016/03/05 出場，扣除交易成本後報酬率為 5%，同時該交易期間標竿 ETF 的報酬為 3%，則可計算出超額報酬為 2%。本研究採用的標竿 ETF 為元大寶來台灣 50ETF，將所有交易計算出其超額報酬後，隨機抽取 1,000 筆資料進行 t 檢定，假說設定如下：

$$H_0: \alpha_{\text{策略}} \leq 0$$

$$H_1: \alpha_{\text{策略}} > 0$$

結果如表 4-4，可以看到不論是投信、外資、自營策略其超額報酬皆顯著大於 0，顯示籌碼分析具備投資參考價值。

表 4-4 技術結合籌碼策略報酬 t 檢定結果

策略	t 值	p-value
投信	2.9835	0.0015
外資(對照組)	2.7405	0.0031
自營(對照組)	2.7485	0.003

確認技術與籌碼分析能夠有效結合後，接下來進一步將策略基金化，模擬實際交易情況，回測設定條件如下：

1. 初始資金：1 千萬元
2. 投資期間：2008/1/1 - 2017/11/14
3. 投組建構：依照訊號進行買進賣出，每筆訊號投入 10% 淨資產金額
4. 若同一天同時觸發多個進場訊號，以 5 日均量/20 日均量進行比較，值高者優先買進
5. 假設無成交量限制，亦即目標買進股票數量市場皆能滿足。
6. 無風險利率為 2008-2017 的一年定存利率複利後的年化報酬：0.6%

回測結果如表 4-5，可以看到三組擇時策略在各方面的表現皆優於買進持有台灣 50ETF，其中投信策略的表現最為突出，如圖 4-4 在 2008 年金融海嘯後創下最大回撤，但還是優於外資策略和大盤 ETF，接下來除了 2011 歐債危機的影響有較大回撤外，其餘時間基本上維持穩定向上且強於大盤的走勢，代表在金融環境較穩定的情況下，投信之選股操作能力能夠帶來穩定的超額報酬。總結此小節的策略，不論是從平均績效分析、超額報酬檢定，或是模擬基金的分析，都能確認技術結合籌碼的策略之有效性，其中以投信的買賣超最具交易、投資參考價值，此結果與陳彥豪(2002)指出投信在短期股價的影響力大於外資的現象不謀而合。

表 4-5 技術結合籌碼策略基金績效

策略	累積報酬	年化報酬	最大回撤	Sharpe ratio
台灣 50ETF	99.25%	6.8%	54.7%	0.42
投信	347.13%	16.41%	44.6%	0.74
外資(對照組)	173.05%	10.74%	53.08%	0.53
自營(對照組)	207.61%	12.12%	41.6%	0.57




圖 4-4 技術結合籌碼策略基金累積報酬走勢

### (三) 深度學習結合股票三大分析之交易策略

上述兩個策略皆有其優缺，第一個基本面策略具備良好的獲利性，但淨值回撤風險高，而第二個技術結合籌碼策略雖然獲利能力較低，不過擇時進出策略使得整體風險有效降低，因此本研究認為將兩者結合能夠產生互補效果，使得整體績效進一步提升，風險亦能控制在一定範圍。接下來說明兩策略之結合方法，深度學習藉由基本面所篩選出的股票代表未來一季可能較為強勢，能夠提供一個明確的交易方向，因此選出預測值 $\geq 0.5$ 且分數前 500 高的股票作為擇時進出的股票池，接續等待股票池中的股票發出技術與籌碼策略的進出場訊號才予以買進賣出，藉此擇時方式調整投組持股水位，如空頭發生時，多數股票均線會成空頭排列，法人買超亦減少，此時發出買進訊號的頻率會相對多頭市場來得低，自然投資組合的持股水位就會偏低。結合後策略的平均績效表現如表 4-6，能夠看到不論是哪一個組別，皆出現交易次數大幅下降、持有期間上升的狀況，但同時平均報酬皆能提升 1~2%，勝率和獲利因子也有明顯改善。進一步將策略的超額報酬隨機抽取 1,000 筆，進行 t 檢定，假說如 4-1-2 的設定，結果如表 4-7，三組超額報酬皆呈顯著 $>0$ ，代表此策效將上述兩個策略做到有效的整合，創造顯著的超額報酬，證明深度學習於策略的有效應用，以及股票三大分析相互結合確實能夠達到相輔相成的效果。

表 4-6 三大分析策略平均績效

策略平均績效					
策略	投信		外資(對照組)		外資(對照組)
結合前後	後	前	後	前	後
平均報酬	5.24%	3.41%	2.47%	1.64%	3.15%
勝率	46.85%	43.02%	38.4%	36.5%	41.4%
獲利因子	2.41	1.87	1.71	1.47	1.9
平均持有天數	59	50	47	43	49
交易次數	2,664	15,175	5,589	38,903	2,09

表 4-7 三大分析策略報酬 t 檢定結果

策略	t 值	p-value
投信	6.27	2.682E-10
外資(對照組)	3.2967	0.0005
自營(對照組)	5.771	5.254E-09

最後，再將此投信策略進行基金化，確認實際交易情況，並加入前兩個策略的基金績效做為比較，整體回測設定如同 4-2-2 基金化之設定，績效表現如表 4-8，可以看到最後的深度學習結合三大分析之交易策略，適當地結合前兩小節的策略，由兩個表現平平的策略成為一個績效優異的策略，年化報酬達 26.86%，並有效控制最大回撤於 33.12%，夏普值亦有 1 以上之水準，由圖 4-5 更能看出結合後的策略與其他策略之差距，穩定向上的走勢代表其可觀的獲利能力，此結果為本研究欲達成目標之一，每一面向的分析皆有其價值，若妥善運用它們，便能發揮最大效益，獲取最佳的報酬。

本研究將於下一節進行穩健性測試，分析模型之穩定性、模擬市場情境，以及參數敏感度分析，強化此篇研究結果之參考價值。

表 4-8 三大分析策略基金績效

策略	累積報酬	年化報酬	最大回撤	Sharpe ratio
台灣 50ETF	91.3%	6.80%	54.7%	0.46
深度學習	217.69%	12.44%	57.72%	0.66
技術+籌碼	287.2%	15.1%	42.14%	0.7
三大分析	887.89%	26.86%	33.12%	1.13




圖 4-5 三大分析策略基金累積報酬走勢圖

## 第二節 穩健性測試

### (一) 衡量深度學習選股模型之穩健性

由於深度學習使用梯度下降法搜尋最佳參數，因此訓練出的模型之參數有可能會落入區域最佳解，而不是全域最佳解，使得同一樣本資料所訓練出的模型選出來的強勢股票不盡相同，因此本研究藉由重複訓練模型，觀察每一次樣本外之結果狀況，確認此方法下的深度學習選股模型是否穩健。本研究以 8 季歷史資料做滾動訓練，因此完整一輪的訓練可以產生 47 個選股模型，將 47 個樣本外強弱勢股票報酬的差距進行平均，便能得到該輪訓練平均強弱勢報酬差距，經過重複 20 輪訓練後結果如圖 4-6，可以看到 20 輪的訓練僅有 1 期差距略低於 3%，而 20 輪整體平均值為 3.41%，即便每輪結果不同，但整體分布是相當均勻，代表此選股策略能夠穩定分辨下一季強弱勢股票，具備相當程度的穩定性。






圖 4-6 模型平均表現

## (二) 流動性限制及市場胃納程度

先前的基金模擬皆是在沒有流動性限制的假設下進行，預定買進的部位皆能夠依照預定的成本價買入，然而市場實際供需的狀況會大幅影響買進賣出的價格，為模擬此一情境，本研究在以開盤價買入的狀況下，設定最大可買進數量如下式：

$$\text{最大可買進數量} = \frac{\text{五日成交均值} \times 5\%}{\text{開盤買入價格}} \quad (4.1)$$

此外，不同的資金規模亦對於報酬率造成不同的影響，代表著市場對於策略的胃納程度，此前的基金模擬皆設定 1,000 萬做為初始資金，接下來加入 3,000 萬/5,000 萬/1 億的測試，檢驗策略在流動性限制下，對於逐漸放大的初始資金是否能夠維持一定的績效水準。結果如表 4-9，可以看到 1 千萬的初始資金即便有流動性限制下，其表現優於無流動性限制下的表現，可能的原因在於流動性的限制使得投資組合持有的股票數量上升，增加買進大幅上漲股票的可能性，同時降低績效回撤幅度，然而隨著資金規模持續上升，運用效率逐漸下降，可以看到平均資金閒置率隨著初始資金規模同步上揚，最高來到將近 30%，不過整體而言，各資金規模下，年化報酬皆能維持在 15% 以上，夏普值均有 0.8 以上的水準，從圖 4-7 能看到各基金的績效多數時間處於向上走勢，少有較大回撤，亦優於買進持有台灣 50ETF，顯示此策略在流動性及各資金規模下，仍可維持不錯的水準，投資人能夠自行彈性調整資金規模，進而達成目標報酬率。

表 4-9 各資金在流動性限制下基金績效

策略	累積報酬	年化報酬	最大回撤	Sharp
1 千萬，無流動性限制	887.89%	26.86%	33.12%	1.
1 千萬，5% 限制	991.48%	28.18%	30.92%	1.
3 千萬，5% 限制	596.8%	22.34%	30.46%	1.
5 千萬，5% 限制	433.74%	19%	29.94%	0.
1 億，5% 限制	296.27%	15.38%	27.99%	0.




圖 4-7 各資金規模在流動性限制下之策略基金累積報酬走勢

### (三) 參數敏感度分析

在技術結合籌碼分析的策略設計中，雖無設計參數最佳化的流程，但此小節將進行參數的調整，目的在於驗證策略是否有過度適配(Overfitting)之嫌，若有過度適配的問題，一旦稍微調動參數便會使得績效大幅下降。

在先前的實證結果中，投信的指標明顯優於外資及自營商，本研究認為其為策略之關鍵進出場條件，所以在更動投信買賣超比率的參數時，勢必影響策略績效，而關注重點在於買超比率之參數與績效應成正比關係，績效不因參數調整而不規則的變動。投信買超的進場條件為公式(13)，初始設定為 5%；而投信賣超的出場條件為公式(14)，初始設定為-2.5%，因此參數範圍設定如下：

1. 近五日投信買超 **穿越** 參數  $x$  (1%~10%)
2. 近五日投信賣超 **小於** 參數  $0.5x$

結果如圖 4-8，參數上升至 8% 以前，策略平均報酬隨之提升，但參數升至 8% 後，平均報酬不升反降，原因為買賣條件趨嚴使得許多擁有潛在獲利機會的交易被篩除，不過整體而言，初始參數 5% 上下的參數皆無出現異常的波動，代表此投信指標具備相當的穩定度，而圖 4-9 顯示各參數之基金在 1 千萬資金規模下，各組合績效之落差來自於平均報酬的差距外，交易次數的多寡亦對績效有著重要的影響，綜觀整體績效來說，除了最下面參數 1% 的績效表現較差外，其餘的基金皆有年化報酬 20% 以上的表現，且大部分時間的走勢非常相似，能夠再次確認此指標之參數穩定性。




圖 4-8 各參數下策略平均報酬




圖 4-9 各參數之策略基金累積報酬走勢

## 第五章 結論與建議

### 第一節 結論

本研究欲達成的目的如下：

1. 建立深度學習與三大分析的量化交易策略
2. 確認深度學習應用於量化交易策略的可行性
3. 驗證三大分析的結合有助於策略表現

透過對台灣所有上市櫃股票進行回測，分別建立深度學習於基本面選股策略以及技術結合籌碼分析之擇時策略，最後將兩策略進行結合，各策略之績效如表 5-1：

表 5-1 各策略績效統整

策略	累積報酬	年化報酬	最大回撤	Sharpe ratio
深度學習	217.69%	12.44%	57.72%	0.66
技術+籌碼	287.2%	15.1%	42.14%	0.7
三大分析	887.89%	26.86%	33.12%	1.13

10 年回測期間，結合三大分析策略之基金年化報酬可達 26.86%，證實三大分析皆具備應用價值，若能妥善運用便能創造更高的附加效益。為更進一步強化實證價值，本研究在穩健性測試中，驗證深度學習於基本面選股策略，經過 20 輪測試下，雖然每一次結果不盡相同但差異不大，強弱勢股票報酬平均差距 20 輪均值為 3.41%，顯示深度學習模型具備穩定及優良的選股能力，再次確認深度學習應用於交易策略之可行性以及穩健性；為趨近市場真實交易狀況，於策略加入流動性限制以及資金規模測試，結果顯示策略報酬仍可維持良好的水準；最後針對關鍵指標－投信買賣超進行參數敏感度測試，結果顯示在 1-10% 的參數範圍中，大部分參數之績效不會因參數稍微變動而有大幅改變，代表此指標



具備相當的穩定度。

透過上述三大目標的達成及穩健性測試，本研究欲傳達的價值及貢獻為：

1. 深度學習之選股目前雖屬黑盒子之結果，但本研究透過多期樣本及多輪測試確認其穩定性及參考價值，投資人不應過度排斥深度學習於交易策略之應用，反而應適當地善加利用。
2. 本研究最終的交易策略由兩個策略結合而成，一個是機器做決策的策略，一個是人為投資邏輯建構的策略，兩策略之結合象徵人腦與電腦的結合，如同三大股票分析一般，適當地結合可能產生更高的效益，也能加深投資人對策略的信心。
3. 三大股票分析方法皆有其價值，本研究結合深度學習提供投資人一個完整的策略架構以利參考。

## 第二節 後續建議

本研究認為交易策略之研究發展能深能廣，以下就深度及廣度兩大面向提供後續的研究方向。

1. 深度：主要往策略之架構、細節發展，例如：越大的資金規模必然使得資金運用效率降低，進而拖累績效，可進一步研究如何使用閒置資金提升策略表現，如分批進場、策略避險、資產配置、參數選擇…等。
2. 廣度：往策略之多元性發展，例如：測試策略在其他市場(中國股市、美國股市…等)的表現、加入其他基本面因子、使用不同的技術指標或是籌碼資訊…等。

## 參考文獻

### 第一節 中文文獻

- 謝信誠(2017)，「技術分析型態辨識與機器學習之 Smart Beta 交易策略應用」，碩士論文，國立中山大學財務管理學系。
- 邱科毓(2014)，「均線分析投資績效探討：以臺灣 50 指數成份股為例」，碩士論文，國立中山大學財務管理學系。
- 陳彥豪(2002)，「外資與投信法人持股比率變化對股價報酬率影響之研究-以上市電子股為例」，碩士論文，國立中山大學財務管理學系。
- 陳炫燐(2015)，「日本 K 線型態理論在期貨當日沖銷交易之實證-以台股指數期貨為例」，碩士論文，銘傳大學財務金融學系
- 陳渝雯(2017)，「台灣股市因子模型之研究與應用-以產業類別分析」，碩士論文，國立中興大學高階經理人碩士在職專班
- 賴靖宜、董澍琦、楊聲勇、苗建華(2011)，「價值投資：財務報表與公開資訊之應用」，證券市場發展季刊，第 22 卷第 4 期，123-182。
- 查欣瑜(2011)，「法人籌碼對台股未來走勢影響之研究」，碩士論文，國立交通大學，財務金融學系
- 李雅璇(2013)，「以巴菲特選股模式建構基本面投資組合：在台股之實證研究」，碩士論文，國立中央大學財務金融學系
- 蘇明南(2002)，「移動平均線法則應用於台灣股市之實證研究」，碩士論文，淡江大學財務金融學系
- 黃鐘億(2008)，「以改良式倒傳遞類神經網路運用成分股與技術指標預測台灣 50 指數報酬率之研究」，碩士論文，國立臺北大學企業管理學系
- 黃祺敦(2012)，「運用當日籌碼面變數預測隔日股價方向」，碩士論文，國立中正大學國際經濟研究所
- 蔡佩恂(2017)，「價值投資在台灣股市之實證：股利殖利率與 F-SCORE」，碩士論文，逢甲大學財務金融學系
- 劉瑞翔(2016)，「探討外資及投信法人於台股買賣群聚行為之成因及影響」，碩士論文，銘傳大學財務金融學系

饒瑞鵬(2006)，「多因子標準化變量相關係數加權法—在股市建構投資價值指標之選股決策運用」，碩士論文，國立屏東科技大學工業管理系

陳彬洲(2015)，「基本面、籌碼面與總體面對股票報酬影響」，碩士論文，亞洲大學財務金融學系碩士在職專班

曲恬頤(2009)，「運用決策樹與倒傳遞類神經網路建構台股之整合性投資策略」，碩士論文，國立清華大學工業工程與工程管理學系

## 第二節 英文文獻

- Bianchi, R., Drew, M. and Fan, J. (2015). Combining momentum with reversal in commodity futures. *Journal of Banking & Finance*, 59, pp.423-444.
- Chen, S., Bao, S. and Zhou, Y. (2016). The predictive power of Japanese candlestick charting in Chinese stock market. *Physica A: Statistical Mechanics and its Applications*, 457, pp.148-165.
- Douglas Foster, F., Gallagher, D. and Looi, A. (2011). Institutional trading and share returns. *Journal of Banking & Finance*, 35(12), 3383-3399.
- Farias Nazário, R., e Silva, J., Sobreiro, V. and Kimura, H. (2017). A literature review of technical analysis on stock markets. *The Quarterly Review of Economics and Finance*, 66, pp.115-126.
- Ferreira, M., Matos, P., Pereira, J. and Pires, P. (2017). Do locals know better? A comparison of the performance of local and foreign institutional investors. *Journal of Banking & Finance*, 82, 151-164.
- Hao, Y., Chou, R., Ho, K. and Weng, P. (2015). The impact of foreign institutional traders on price efficiency: Evidence from the Taiwan futures market. *Pacific-Basin Finance Journal*, 34, pp.24-42.
- Hsu, P., Hsu, Y. and Kuan, C. (2010). Testing the predictive ability of technical analysis using a new stepwise test without data snooping bias. *Journal of Empirical Finance*, 17(3), pp.471-484.
- Marshall, B., Young, M. and Rose, L. (2006). Candlestick technical trading strategies: Can they create value for investors?. *Journal of Banking & Finance*, 30(8), pp.2303-2323.
- Menkhoff, L. (2010). The use of technical analysis by fund managers: International evidence. *Journal of Banking & Finance*, 34(11), pp.2573-2586.
- Mohanram, P. (2003). Separating Winners from Losers among Low Book-to-Market Stocks using Financial Statement Analysis. *Available at SSRN:403180*
- Papailias, F. and Thomakos, D. (2015). An improved moving average technical trading rule. *Physica A: Statistical Mechanics and its Applications*, 428, pp.458-469.
- Piotroski, J. (2000). Value Investing: The Use of Historical Financial Statement Information to Separate Winners from Losers. *Journal of Accounting Research*, 38, p.1.

- Sezer, O., Ozbayoglu, M. and Dogdu, E. (2017). A Deep Neural-Network Based Stock Trading System Based on Evolutionary Optimized Technical Analysis Parameters. *Procedia Computer Science*, 114, 473-480.
- Shynkevich, A. (2012). Performance of technical analysis in growth and small cap segments of the US equity market. *Journal of Banking & Finance*, 36(1), pp.193-208.
- Szakmary, A., Shen, Q. and Sharma, S. (2010). Trend-following trading strategies in commodity futures: A re-examination. *Journal of Banking & Finance*, 34(2), 409-426.
- Vanstone, B., Finnie, G. and Hahn, T. (2012). Creating trading systems with fundamental variables and neural networks: The Aby case study. *Mathematics and Computers in Simulation*, 86, pp.78-91.
- Zheng, D., Li, H. and Zhu, X. (2015). Herding behavior in institutional investors: Evidence from China's stock market. *Journal of Multinational Financial Management*, 32-33, 59-76.
- Zhu, M., Atri, S. and Yegen, E. (2016). Are candlestick trading strategies effective in certain stocks with distinct features?. *Pacific-Basin Finance Journal*, 37, 116-127.

## 附錄

### (一) 129 個財報因子彙整表

現金比率	固定資產比率	長期負債比率
現金比率季變動	固定資產比率季變動	長期負債比率季變動
現金比率年變動	固定資產比率年變動	長期負債比率年變動
應收帳款比率	流動比率	總負債比率
應收帳款比率季變動	速動比	總負債比率季變動
應收帳款比率年變動	流動負債比率	總負債比率年變動
存貨比率	流動負債比率季變動	利息保障倍數
存貨比率季變動	流動負債比率年變動	利息支出比率
存貨比率年變動	長期資金適合率	普通股股本
普通股股本季變動	近四季平均營業利益率	近四季每股盈餘
普通股股本年變動	近四季平均營業利益率季增率	近四季每股盈餘季增率
特別股股本	近四季平均營業利益率年增率	近四季每股盈餘年增率
特別股股本季變動	累計 EBIT	累計 ROE
特別股股本年變動	累計 EBI 季增率	累計 ROE 季增率
未分配盈餘	累計 EBI 年增率	累計 ROE 年增率
總權益	單季 EBIT	單季 ROE
總權益季變動	單季 EBIT 季增率	單季 ROE 季增率
總權益年變動	單季 EBIT 年增率	單季 ROE 年增率
累計每股營收	近四季 EBIT	四季平均 ROE
累計每股營收季增率	近四季 EBI 季增率	四季平均 ROE 季增率
累計每股營收年增率	近四季 EBI 年增率	四季平均 ROE 年增率
單季每股營收	累計稅後淨利率	累計 ROA
單季每股營收季增率	累計稅後淨利率季增率	累計 ROA 季增率
單季每股營收年增率	累計稅後淨利率年增率	累計 ROA 年增率
近四季每股營收	單季稅後淨利率	單季 ROA
近四季每股營收季增率	單季稅後淨利率季增率	單季 ROA 季增率

近四季每股營收年增率	單季稅後淨利率年增率	單季 ROA 年增率
累計毛利率	近四季稅後淨利率	四季平均 ROA
累計毛利率季增率	近四季稅後淨利率季增率	四季平均 ROA 季增率
累計毛利率年增率	近四季稅後淨利率年增率	四季平均 ROA 年增率
單季毛利率	累計營業集中度	研發費用率
單季毛利率季增率	累計營業集中度年增率	總資產周轉率
單季毛利率年增率	累計營業集中度年增率	應收帳款周轉率
近四季平均毛利率	單季營業集中度	存貨周轉率
近四季平均毛利率季增率	單季營業集中度季增率	固定資產周轉率
近四季平均毛利率年增率	單季營業集中度年增率	權益周轉率
累計營業利益率	累計每股盈餘	應付帳款付現天數
累計營業利益率季增率	累計每股盈餘季增率	應收帳款佔營收比重
累計營業利益率年增率	累計每股盈餘年增率	存貨佔營收比重
單季營業利益率	單季每股盈餘	PB / PE / 市值
單季營業利益率季增率	單季每股盈餘季增率	自由現金流比率
單季營業利益率年增率	單季每股盈餘年增率	股利殖利率/現金殖利率

\*本研究自行整理

## (二) 47 輪因子挑選統整

因子	被挑選次數
近 4 季 ROE	39
單季 ROA	36
近 4 季 ROA 季增率	30
累計應收帳款周轉率	30
累計稅後淨利年增率	30
營業利益年增率	30
營業利益季增率	30
單季稅後淨利季增率	30
近 4 季 ROE 年增率	29

存貨周轉率	29
資產周轉率	28
淨值周轉率	28
長期資金適合率	28
累計稅後淨利年增率	28